



Gitterbasierte Umfeldmodellierung mittels Laserscanner für das automatisierte Fahren

Studienarbeit

erstellt von cand. mach.
Braunschweig, im Januar 2021

Technische Universität Braunschweig
Institut für Fahrzeugtechnik
Direktor: Prof. Dr.-Ing. Ferit Küçükay
Betreuer: M.Sc. Marcel Mascha

Aufgabenstellung (Original bzw. Kopie)

Sperrklausel

Die Ausgabe der vorliegenden Studienarbeit mit dem Titel „Gitterbasierte Umfeldmodellierung mittels Laserscanner für das automatisierte Fahren “ ist ausschließlich unter Genehmigung der Institutsleitung zulässig.

Braunschweig, den 04.Januar 2021

Eidesstattliche Erklärung

Ich versichere an Eides statt, dass ich die vorliegende Studienarbeit mit dem Titel „Gitterbasierte Umfeldmodellierung mittels Laserscanner für das automatisierte Fahren“, ohne unerlaubte fremde Hilfe oder Beratung und nur unter Verwendung der angegebenen wissenschaftlichen Hilfsmittel angefertigt habe.

Braunschweig, den 04. Januar 2021

Xiantao Chen

Kurzfassung

Inhaltsverzeichnis

Abbildungsverzeichnis	VIII
Tabellenverzeichnis	IX
Abkürzungsverzeichnis	X
Symbolverzeichnis	XI
1 Einleitung	1
1.1 Einführung	1
1.2 Zielstellung	2
1.3 Aufbau	2
2 Theoretische Grundlagen	3
2.1 Umfeldmodellierung	3
2.1.1 Mögliche Umfeldmodelle	3
2.1.2 Objektbasierte Modelle	4
2.1.3 Gitterbasierte Modelle	5
2.1.4 Hybride Umfeldmodelle	12
2.2 Sensorik und ihr inverses Sensormodell	12
2.2.1 Überblick über verschiedener Sensoren zur Umfeldmodellierung	13
2.2.2 Laserscanner	16
3 Implementierung	17
3.1 Unterkapitel 1	17
3.1.1 Unterunterkapitel1	17
Literatur	21
Anhang	23

Abbildungsverzeichnis

2.1	Mögliche Umfeldmodelle für autonome Fahrzeuge	4
2.2	Ein objektbasiertes Umfeldmodell. [FHR ⁺ 20]	5
2.3	Zwei Ebenen von Occupancy Grid	5
2.4	Raumdiskretisierung der Umgebung um Fahrzeug [WHLS15]	6
2.5	Bestandteile des Modells Ocuupancy Grid	7
2.6	Hidden Markov Model (HMM) [TBF05]	8
2.7	Das reduzierte HMM [TBF05]	10
3.8	Folgefahrt Beispielbild	17

Tabellenverzeichnis

2.1	Der Algorithmus des Bayes-Filters [TBF05]	8
2.2	Vorteile und Nachteile von Kamera, fernes Infrarotsensor, Radar, Ultraschall- und Lidarsensor	13
3.1	Tabular Umgebung: Simpel formatierte Tabelle	18
3.2	Vorteile und Nachteile von Kamera, Radar-, Lidar- und Ultraschall- sensor	19
3.3	Tabular Umgebung: Etwas komplexere Tabelle	20

Abkürzungsverzeichnis

IfF Institut für Fahrzeugtechnik

Symbolverzeichnis

Δh_{ax}	$[\text{m/s}^2]$	Überschwingweite
------------------------	------------------	------------------

1 Einleitung

Im ersten Kapitel wird auf die Einführung des Themas, das zu erreichende Ziel und der Aufbau dieser Arbeit eingegangen.

1.1 Einführung

Das Thema „Autonomes Fahren“ ist in den vergangenen Jahren immer weiter in den Vordergrund gerückt. Selbstfahrende Autos verlagerten sich allmählich von Laborentwicklungs- und Testbedingungen auf öffentliche Straßen. Die Konzept, dass Autos autonom fahren können, beschäftigte die Menschen schon in den 1920er-1930er-Jahren.

Um das Konzept praxistauglich zu machen, braucht es das kombinierte Wissen unter anderem aus Informatik, Fahrzeugtechnik, Sensorik, Mechatronik. Unter dem Begriff „Autonomes Fahren“ werden Fahrzeuge gefasst, die ohne Eingriff und Überwachung durch einen Menschen selbstständig sowie ziel gerichtet im Straßenverkehr fahren können.

Ingenieure für selbstfahrende Autos verfolgen aktuell zwei wesentliche und unterschiedliche Herangehensweisen für autonome Entwicklung, welche aus Robotik-Ansatz und Deep-Learning-Ansatz bestehen. In den vergangenen zwei Jahrzehnten hat der Robotik-Ansatz mit einer Menge von Beiträgen der zahlreichen Wissenschaftler und Technik sowohl in Akademie als auch in technologisch führenden Unternehmen großen Fortschritt gemacht.

Im Rahmen dieser Arbeit handelt es sich um ein statisches Umfeld. Sollte die Echtzeitanforderung berücksichtigt, ist der Deep-Learning Ansatz zu verzichten, denn es ist mit vielen Literaturen bewiesen, dass ein statisches Umfeld mit Robotik-Ansatz zutreffend und effizient modelliert werden kann.[TBF05]

Die zentrale Idee des Robotik-Ansatzes ist, dass die Unsicherheit in der Robotik sich unter Verwendung der Wahrscheinlichkeitsrechnung darstellen lässt.

1.2 Zielstellung

Um das automatisierte Fahren zu verwirklichen, wird die Umfelderkennung bzw. die Umfeldmodellierung des Fahrzeugs zugrunde gelegt. Das Ziel der vorliegenden Arbeit ist auf Modellierung und dazu ihre Implementierung gerichtet.

1.3 Aufbau

Nach dieser Einleitung wird im Kapitel 2 die technische Grundlagen, welche sich eng mit Erfassung und Modellierung eines statischen Umfelds beziehen.

2 Theoretische Grundlagen

Um das in Einleitung 1.2 erwähnte Ziel zu erreichen, sollten zunächst die theoretische Grundlagen geschaffen, bevor die praktische Umsetzung bzw. Implementierung stattfindet. Im Folgenden werden die für Umfeldmodellierung relevanten Theorie vorgestellt. Es ist offensichtlich, dass für die Umfeldmodellierung eine Wahrnehmung über das Umfeld gefordert, weshalb die für Umfeldwahrnehmung Sensorik darauffolgend gesprochen wird.

2.1 Umfeldmodellierung

Für Perzeption eines autonomen Fahrzeuges gibt es im wesentlichen zwei Bestandteilen [BGC⁺19]. Zum einen ist die Lokalisation. Die aktuelle Pose, das heißt die Position und Orientierung des eigenen Fahrzeuges, ist hierbei zu ermitteln. Zum anderen ist die Umgebung um das Fahrzeug zu erfassen. Dabei wird es als Umfeldmodellierung genannt. Diese zwei Aspekte werden in vieler Forschung und Anwendung als ein Problem gekoppelt. Dies ist als SLAM (Simultaneous localization and mapping) bekannt. Jedoch trennen sich diese zwei Aspekte im Rahmen dieser Arbeit und die Aufmerksamkeit ist auf Umfeldmodellierung zu lenken. Hierbei wird eine Annahme getroffen, dass die Eigenpose des Fahrzeugs ohne Information der Umfeldmodell genug präzise ist. Im bestehenden iff-Framework wird die Eigenpose mit GPS-Daten unter Anwendung des Kalman-Filters übergeben.

In Bezug auf Robotik und autonomes Fahren dient Umfeldmodellierung als ein kompaktes Verfahren zu der mathematischen Repräsentation von der Umgebung um ein Auto.[Pie13] Das schafft eine unentbehrliche solide Grundlage, auf der der Entwurf und die darauffolgende Verwirklichung aller höheren automatisierten Fahrfunktion.

2.1.1 Mögliche Umfeldmodelle

Methoden zur Modellierung eines Umfelds basieren sich auf verschiedene entsprechenden Umfeldmodelle. Die maßgebliche Umfeldmodelle bauen auf erfolgreichen Erfahrung in dem Themenbereich der Robotik[Pie13]. Wie in Abbildung 2.1 ge-





Abbildung 2.1: Mögliche Umfeldmodelle für autonome Fahrzeuge

zeigt, stehen aktuell in Forschung und Automobilindustrie meistens drei mögliche Umfeldmodelle zur Verfügung[Heg18].

2.1.2 Objektbasierte Modelle

Objektbasierte Modelle werden auch als merkmalsbasierte Umfeldmodelle (engl. landmark-based oder feature map) genannt[TBF05]. Hierbei werden die Merkmalen, die für Erfassung der Umgebung günstig sind, durch Modelle beschrieben werden[WSG10]. Außerdem sollten die Merkmalen zuverlässig beobachtet und gemessen werden[Bus05]. Die Modelle werden in der Praxis als bestimmte Objektklasse beschrieben. Jede Klasse wird mit hervorstechenden und maßgeblichen Eigenschaften versehen, die deutlich durch die zutreffende Sensorik beobachtbar ist[WHLS15]. Für die Klassen lassen sich darüber hinaus die zu Objekt passende Geometrieformen bestimmen[Pie13]. Daher ist die Performance des Modells abhängig davon, ob die zu modellierten Objekte genug präzise und einfach beschrieben werden können. Hierbei sind die Genauigkeit gegen den Zeit- und Speicheraufwand abzuwägen. Ein Beispiel ist ein in Abbildung 2.2 gezeigtes Umfeldmodell. Auf der linken Seite sind Merkmale dargestellt und das Bild rechts zeigt das generierte Umfeldmodell.

Objektbasierte Umfeldmodelle sind vor allem geeignet für Szenen, wo die Objekte entweder im großen offenen Räume mit vordefinierten Merkmalen (z.B. Autobahn) oder dynamisch und einfach modelliert (z.B. Fußgänger oder Fahrzeuge) sind[Heg18][WSG10]. Da es im Rahmen dieser Arbeit ein statisches Umfeld im urbanen Raum angeht, ist dieses Modell ungeeignet und daher zu verzichten.

Abbildung 2.2: Ein objektbasiertes Umfeldmodell. [FHR⁺20]

2.1.3 Gitterbasierte Modelle

In gitterbasierten Modellen wird die zentrale Idee der probabilistischen Robotik eingeführt, die Wahrscheinlichkeitsverteilung unbeobachteter Zustände eines Systems bei gegebenen Beobachtung und Messungen zu schätzen. Zur Modellierung des Umfelds ist der zentrale und entscheidende Zustand der sogenannte Belegungszustand. Der Belegungszustand erweist sich, ob eine Gitterzelle belegt ist. Daraus ergibt sich eine Zufallsvariable X , den Belegungszustand repräsentiert. Die Variable X kann zwei Werte annehmen, welche 0 und 1 sind. Die entsprechen dabei, dass das Gitter frei und belegt ist.

Ein Modell, welches auf der obenerwähnten Idee aufbaut, wird als Occupancy Grid beschrieben. Das Occupancy Grid ist ein mehrdimensionales Zufallsfeld, das stochastische Schätzungen des Belegungszustands der Zellen in einem räumlichen Gitter halten [Elf89]. Wie in Abbildung 2.3 gezeigt, lässt Occupancy Grid sich in zwei Ebenen zerlegen.

1	Raumdiskretisierung
2	Probabilistischer Ansatz

Abbildung 2.3: Zwei Ebenen von Occupancy Grid

Auf der ersten Ebene wird die Raumdiskretisierung ausgeführt. Im Rahmen dieser

Arbeit wird das Umfeld als zweidimensionalen Raum dargestellt. Die Diskretisierung des Raumes bedeutet hierbei, dass die Fahrzeugumgebung durch Gitter diskreter und fester Größe dargestellt wird [Heg18]. Die grafische Darstellung ist in Abbildung 2.4 gezeigt. Außerdem wird jeder Zelle zusätzliche Informationen hinzugefügt. In Hinsicht auf Umfeldmodellierung ist die entscheidende Information die Belegungszustand der Zelle. Zur Vereinfachung der Modellierung, wird eine Annahme auf dieser Ebene zugleich getroffen, dass die Belegungszustand einer Gitterzelle ist unabhängig von diejenige der Nachbarzellen. Obwohl die Annahme anders als Realität aussieht, ist es erwiesen, dass Occupancy Grid Modell in Praxis unter dieser Annahme robust ist und zudem die Rechenkomplexität reduzieren kann [TBF05].




Abbildung 2.4: Raumdiskretisierung der Umgebung um Fahrzeug [WHLS15]

Auf der zweiten Ebene ist der probabilistische Ansatz eingeführt, welcher aus Theoriengebiet von Robotik stammen [Pie13]. Der Ansatz beruht auf Raumdiskretisierung und wird in der Praxis für jede einzelne Zelle eingesetzt. Der Ansatz lässt sich, wie in Abbildung 2.5 gezeigt, in viele Komponenten aufteilen. Im Zentrum des Modells steht ein Algorithmus-Framework, der als binärer Bayes-Filter (engl. Binary Bayes Filter) bekanntlich ist. Die Eingaben von dem Framework bestehen aus Messungswerte, inverses Sensormodell und Anfangsbedingungen. Die Ausgabe ist A-posteriori-Wahrscheinlichkeit von dem Zufallsereignis, wenn die Zelle belegt ist.

Um die Konzept von Occupancy Grid zu beleuchten, wird im Folgenden auf jede Komponente vertieft eingegangen.



Abbildung 2.5: Bestandteile des Modells Ocuupancy Grid

Der Binary-Baye-Filter ist zuerst zu beleuchten, mit dem die Funktionen und Bedeutungen von anderen Bestandteilen des Modells eng verbunden sind. Der Bayes-Filter ist ein rekursives Berechnungsvorschrift zur Schätzung von Wahrscheinlichkeitsverteilungen unbeobachteter Zustände eines Systems bei gegebenen Beobachtungen und Messungen [TBF05]. Die Zustandsschätzung befasst sich mit dem Problem der Schätzung von Größen aus Sensordaten, die nicht direkt beobachtbar sind, aber abgeleitet werden können. Das Ziel ist den Zustand x eines Systems zu schätzen¹, wenn Beobachtung z und Kontrolle u gegeben sind. Das heißt, die in Gleichung 2.1 gezeigte mathematische Formulierung sollte bestimmt werden. Hierbei entspricht x_t Zustand zum Zeitpunkt t . $z_{1:t}$ bezeichnet die Beobachtungen bzw. die Messgrößen von den Zuständen, die sich von Zeitstempel 1 bis t erstrecken. Zudem gibt $u_{1:t}$ die Kontrollen an, die sich von Zeitstempel 1 bis t erstrecken. Die linke Seite der Gleichung $bel(x_t)$ verkörpert den Glauben (engl. belief) der Wahrheit, dass der Zustand x_t ist [TBF05].

$$bel(x_t) = p(x_t | z_{1:t}, u_{1:t}) \quad (2.1)$$

Um die Wahrscheinlichkeitsverteilung einzugehen und eine rekursive Form zu entdecken, ist der stochastische Prozess der Zustandsänderung als Hidden Markov Model

¹Präzis wird den Zustand $X = x$ formuliert, wobei X eine Zufallsvariable ist und x ist der spezifische Wert, den X in Echtzeit annimmt. Zur Vereinfachung der Notation wird die Formulierung $X = x$ im Rahmen dieser Arbeit sowie in vieler Literaturen als x bezeichnet.

(HMM), auch dynamic Bayes network (DBN) genannt, zu betrachten. Unter Anwendung dieser Annahme gilt: Die Wahrscheinlichkeit eines Zustandes bei Zeitstempel t (x_t) ist einschließlich abhängig von Zustand bei Zeitstempel $t - 1$ (x_{t-1}) und nicht von Zuständen bei Zeitstempel, die früher als $t - 1$ sind. Mathematisch wird HMM als eine Gleichung in 2.2 beschrieben.

$$p(x_t|x_{1:t}) = p(x_t|x_{t-1}) \quad (2.2)$$

Außerdem beschreibt Hidden Markov Model, wie in Abbildung 2.6 dargestellt, die vereinfachte Zusammenhang zwischen Zustand x , Messgröße z und Kontrolle u . Der Zustand zum Zeitpunkt t ist abhängig von dem Zustand zum Zeitpunkt $t - 1$ und der Kontrolle u_t . Die Messgröße z_t hängt stochastisch vom Zustand zum Zeitpunkt t ab. Unter zusätzliche Anwendung des Satzes von Bayes und des Gesetzes der totalen




Abbildung 2.6: Hidden Markov Model (HMM) [TBF05]

Wahrscheinlichkeit wird die Formulierung 2.1 in einen rekursiven Ausdruck abgeleitet, was als Bayes-Filter bekanntlich ist. Die Ableitung findet sich in [TBF05]. Der daraus resultierte Algorithmus lautet in Tabelle 2.1: Der Algorithmus umfasst

Tabelle 2.1: Der Algorithmus des Bayes-Filters [TBF05]

Algorithm Bayes Filter($bel(x_{t-1}), u_t, z_t$):
 for all x_t do
 $\overline{bel}(x_t) = \int p(x_t|u_t, x_{t-1})bel(x_{t-1})dx_{t-1}$
 $bel(x_t) = \eta p(z_t|x_t)\overline{bel}(x_t)$
 endfor
 return $bel(x_t)$

2 Schritte, welche als Prädiktion (engl. prediction) und Korrektur (engl. Correction oder update) bekanntlich sind. Der erste Schritt wird dadurch ausführt, dass der

Glauben bzw. die Wahrscheinlichkeitsverteilung über den Zustand x_t - basierend auf dem vorherigen Glauben über den Zustand x_{t-1} und Kontrolle u_t - berechnet werden sollte. Der zweite Schritt ist eine Korrektur bzw. ein Update des prognostizierten Glaubens, indem die beobachteten Informationen des Zustandes bzw. die Messgrößen der Sensorik fusioniert und berücksichtigt wird. Der Wert $bel(x_t)$ wird als A-posteriori-Verteilung genannt. Im Gegensatz zu A-priori-Verteilung verkörpert A-posteriori-Verteilung den theoretisch präziseren Glauben, nachdem die Messgrößen von Sensorik durch ein Sensormodell die Genauigkeit des Glaubens beiträgt. Dieser Algorithmus bildet eine Grundlage, auf der viele weitere Algorithmen für bestimmte Szenarien entwickelt werden. Dazu gehören bekanntlich Gauß-Filter mit ihren Varianten, Particle-Filter und der diskrete Bayes-Filter. Der binäre Bayes-Filter, der eine große Rolle in dieser Arbeit spielt, ist ein spezieller Fall des Bayes-Filters bzw. des diskreten Bayes-Filter.

Eingeführt von dem zugrunde liegenden Bayes-Filters, benötigt der binäre Bayes-Filter eine Annahme. Es ist angenommen, dass der Zustand einschließlich zwei Möglichkeiten besitzen. Das heißt, der Zufallsvariable, der den Zustand repräsentiert, kann nur zwei Werte annehmen. Bei Occupancy Grid kann der wichtige und auch einzige Zustand der Belegungszustand, welche lediglich zwei Fälle - belegt oder frei - sein. Aus diesem Grund ist der binäre Bayes-Filter dafür zutreffend. Darüber hinaus wird eine weitere Annahme getroffen, dass der Belegungszustand bei Occupancy Grid statisch ist. Das heißt, dass der Belegungszustand sich nicht im Laufe der Zeit verändert und die Kontrolle u hat keine Wirkung auf den Belegungszustand. Somit ist das Schema des stochastischen Prozesses der Zustandsveränderung von Abbildung 2.6 auf Abbildung 2.7 reduziert, indem die Kontrollen ausgeklammert werden. Es ist nach dieser zwei Annahme deutlich, dass der Algorithmus des Bayes-Filters in Occupancy Grid den Schritt Prädiktion nicht mehr enthält. Die A-posteriori-Verteilung der Zustand $bel(x_t)$ ist einschließlich berechnet mit Information von Messdaten und der vorherige Zustand $bel(x_{t-1})$.

Anhand der Vereinfachung des Modells sollte der grundlegende Bayes-Filter entsprechend vereinfacht werden. Außerdem sollte der vereinfachte Algorithmus ein inverses Sensormodell. Das inverse Sensormodell gibt anstatt $p(z_t|x)$ eine Verteilung über die binäre Zustandsvariable als Funktion der Messung $p(x|z_t)$ an [TBF05]. Ein Grund, das ein inverses Sensormodell eingesetzt wird, ist die Leichtigkeit, eine Funktion zu entwickeln, die die Wahrscheinlichkeitsverteilung von Sensordaten berechnet. Es ist




Abbildung 2.7: Das reduzierte HMM [TBF05]

zum Beispiel relativ simpel ein Modell zu entwerfen, womit die Wahrscheinlichkeit der Belegungszustand einer Zelle oder mehrerer Zellen anhand der Sensordaten bestimmt werden kann. Ein Vorwärtsensormodell ist dagegen in diesem Fall erstaunlich schwierig. Mit dem Ziel, ein vereinfachter Algorithmus, der ein inverses Sensormodell verwendet, zur Berechnung des Glauben $bel(x_t)$ zu finden, sollte die mathematische Ableitung nach [TBF05] [WSD07] [Heg18] folgend vorgestellt.

Da Belegungszustand statisch ist und Kontrolle u somit ignoriert wird, kann die Zielgleichung 2.1 zur vereinfachten Gleichung 2.3.

$$bel(x_t) = p(x_t | z_{1:t}, u_{1:t}) = p(x_t | z_{1:t}) \quad (2.3)$$

Bei Occuancy Grid ist der interessierte Zustand der Belegungszustand. Zur Vereinfachung der Notation wird das Glauben, dass die Zelle i des Gitters zum Zeitpunkt t belegt ist, als Gleichung 2.4 bezeichnet.

$$bel_t(m_i) = p(m_i | z_{1:t}) \quad (2.4)$$

Analog dafür ergibt sich das Glauben, dass die Zelle i des Gitters zum Zeitpunkt t frei ist, zur Gleichung 2.5

$$bel_t(\overline{m_i}) = p(\overline{m_i} | z_{1:t}) \quad (2.5)$$

Mit Hilfe des bedingten Satzes der Bayes ergibt sich die Gleichung 2.4 zu

$$bel_t(m_i) = p(m_i | z_{1:t}) = \frac{p(z_t | m_i, z_{1:t-1}) p(m_i | z_{1:t-1})}{p(z_t | z_{1:t-1})} \quad (2.6)$$

Unter Annahme eines Hidden-Markov-Modells wird die Gleichung 2.6 zu

$$bel_t(m_i) = \frac{p(z_t|m_i, z_{1:t-1})p(m_i|z_{1:t-1})}{p(z_t|z_{1:t-1})} = \frac{p(z_t|m_i)p(m_i|z_{1:t-1})}{p(z_t|z_{1:t-1})} \quad (2.7)$$

Zur Wahrscheinlichkeit $p(z_t|m_i)$ wird der Satz des Bayes wiederum eingesetzt, womit wird die Gleichung 2.7 zu

$$bel_t(m_i) = \frac{p(z_t|m_i)p(m_i|z_{1:t-1})}{p(z_t|z_{1:t-1})} = \frac{p(m_i|z_t)p(z_t)p(m_i|z_{1:t-1})}{p(m_i)p(z_t|z_{1:t-1})} \quad (2.8)$$

Analog dazu hat der gegenteilige Zustand den Glauben

$$bel_t(\overline{m_i}) = 1 - bel_t(m_i) = \frac{p(z_t|\overline{m_i})p(\overline{m_i}|z_{1:t-1})}{p(z_t|z_{1:t-1})} = \frac{p(\overline{m_i}|z_t)p(z_t)p(\overline{m_i}|z_{1:t-1})}{p(\overline{m_i})p(z_t|z_{1:t-1})} \quad (2.9)$$

Dividiert Gleichung 2.8 durch der Gleichung 2.9, so ergibt sich

$$\frac{bel_t(m_i)}{1 - bel_t(m_i)} = \frac{p(m_i|z_t)}{1 - p(m_i|z_t)} \frac{p(m_i|z_{1:t-1})}{1 - p(m_i|z_{1:t-1})} \frac{1 - p(m_i)}{p(m_i)} \quad (2.10)$$

Die Gleichung 2.10 bietet eine perfekte mathematische Darstellung bzw. Erklärung an, was die Angaben und die Ausgabe des binären Bayes-Filters sind. Die Ausgabe ist das Glauben bzw. die A-posteriori-Wahrscheinlichkeit eines Ereignis, dass die Zelle m_i belegt ist, welches den Term $bel_t(m_i)$ in Gleichung 2.10 entspricht. Der Term $p(m_i|z_t)$ ist, wie oben erzählt, das inverses Sensormodell. Es ist ersichtlich, dass eine bedeutende Zusammenhang zwischen dem Modell bzw. der Beschreibung des Modells und den Arten der Sensoren. Darauf wird in Abschnitt 2.2 mit der Erfassung des Umgebung vertieft eingegangen. Der Term $p(m_i|z_{1:t-1})$ beweist dabei die wichtige Eigenschaft des binären Bayes-Filters, dass das Verfahren der Schätzung auf Rekursion beruht. Die Anfangsbedingung bzw. die A-priori-Wahrscheinlichkeit ist als der Term $p(m_i)$ in Gleichung 2.10 bezeichnet. Die A-priori-Wahrscheinlichkeit gibt den Glauben an, vordem alle Messdaten von Sensorik berücksichtigt werden. Typischerweise wird bei Occupancy Grid anfänglich $p(m_i)$ den Wert 0,5 gegeben, weil es keine Information über die Belegungszustand gibt. Die Wahrscheinlichkeit, dass eine Gitterzelle belegt ist, ist die gleichen wie die, dass sie nicht belegt ist. Daher wird die Gleichung 2.10 zu

$$bel_t(m_i) = \frac{Y}{Y + 1} \quad (2.11)$$

mit

$$Y = \frac{p(m_i|z_t)}{1 - p(m_i|z_t)} \frac{p(m_i|z_{1:t-1})}{1 - p(m_i|z_{1:t-1})} \quad (2.12)$$

Zusammenfassend ist das gitterbasierte Modell eignet für statische Umgebung im urbanen Raum. Außerdem bietet das Modell einen Vorteil, neben belegte Objekte einen Freiraum zu modellieren, was eine Grundlage der darauffolgenden Navigation schaffen.

2.1.4 Hybride Umfeldmodelle

Um ein Umfeld zu modellieren, welches komplizierte Szenarien repräsentieren kann, ist selbstverständlich Hybride Umfeldmodelle aufgefördert. Dadurch lassen sich die Einschränkung von jedem grundlegenden Modell eliminieren und die Vorteilen ausnutzen. Es gibt unterschiedliche Kriterien und Methoden um ein hybrides Umfeldmodell zu bilden. Das Modell, das [0619] angeht, ist ein populäres Beispiel von hybriden Umfeldmodellen. Im Prinzip ist das Modell eine Kombination von einem objektbasierten Umfeldmodell und einem gitterbasierten Umfeldmodell. Hierbei beschreibt das objektbasierte Umfeldmodell dynamische Objekte, wohingegen das gitterbasierten Umfeldmodell bzw. Occupancy-Grid-Map den statischen Raum darstellen. Auf dieser Weise ist das fusionierte Modell generell in der Lage eine Umgebung, wo sich dynamische und statischen Objekte befinden, vollständig und zutreffend zu beschreiben. Darüber hinaus kann die objektbasierte Umfeldmodellierung mit aktueller Technik z.B. Deep-Learning präziser und effizienter durchgeführt werden, während die semantische Navigation noch direkt im gitterbasierten Umfeldmodell verlaufen kann[0619]. Wird die Umgebung im Rahmen dieser Arbeit als ein statisches Umfeld betrachtet, wird ein Hybrides Umfeldmodell wegen Komplexität und Überflüssigkeit nicht angewandt.

2.2 Sensorik und ihr inverses Sensormodell

Zweifellos dient eine Wahrnehmung bzw. eine Erfassung als eine wichtige Voraussetzung zur Umfeldmodellierung, weil sie die Informationsquelle bietet. Wahrnehmung eines Fahrzeugs besteht wesentlich aus die Bestimmung der eigenen Position samt

Orientierung und die Erfassung der Umgebung um das eigenen Fahrzeug. Die Lokalisierung ist im Rahmen dieser Arbeit nebensächlich und durch die vorgegebene GPS-Information bestimmt. Darauf soll an dieser Arbeit nicht näher eingegangen werden.

2.2.1 Überblick über verschiedener Sensoren zur Umfeldmodellierung

Um ein zuverlässiges Umfeldmodell zu entwickeln und danach das Modell in Praxis effektiv umzusetzen, spielt einer Auswahl der erfassenden Sensoren entweder in Akademie oder in Industrie eine große Rolle. Die wichtigsten Fahrzeugsensoren zur Wahrnehmung der Umgebung sind Kameras, fernes Infrarot- (engl. Far-infrared, als FIR gekürzt) Radar-, LiDAR (Light Detection and Ranging) - und Ultraschallsensoren. Nach [MAA⁺20] sind die Vorteilen neben der Nachteilen in Tabelle 2.2 aufgelistet.

Tabelle 2.2: Vorteile und Nachteile von Kamera, fernes Infrarotsensor, Radar-, Ultraschall- und Lidarsensor

Sensor	Vorteile	Nachteile
Kamera	<ul style="list-style-type: none"> • eine hohe Auflösung und Farbskalen über das gesamte Sichtfeld haben • eine farbenfrohe Perspektive der Umgebung bieten • eine 3D-Geometrie von Objekten bei Stereokameras bereitstellen • kostengünstig Im Vergleich zu Lidar sind 	<ul style="list-style-type: none"> • ein leistungsfähiges Berechnungssystem benötigen, um nützliche Daten zu extrahieren • empfindlich auf starken Regen, Nebel und Schneefall reagieren • eine 3D-Geometrie von Objekten bei Stereokameras bereitstellen • begrenzte Reichweite besitzen

FIR-Sensor	<ul style="list-style-type: none">• nicht von der Lichtbedingungen und Objektoberflächenmerkmale beeinflusst werden können• eine bessere Sicht durch Staub, Nebel und Schnee als Kameras haben• eine horizontale Erfassungsbereichweite bis zu 200m oder mehr abdecken• im Vergleich zu Lidar billiger und kleiner sind	<ul style="list-style-type: none">• anspruchsvolle Rechenquellen und robuste Algorithmen erfordern• schwierig Ziele in Szenarien mit kaltem Klima zu unterscheiden• niedrigere Auflösung im Vergleich zur sichtbaren Kamera haben• keine Information über Entfernung bieten
Radarsensor	<ul style="list-style-type: none">• lange Strecken bei schlechten Sichtverhältnissen vor dem Auto sehen• klein, leicht und erschwinglich sind• weniger Strom als ein Lidar-Sensor benötigen• im Vergleich zu Lidar robuster gegen Ausfälle sind	<ul style="list-style-type: none">• eine geringe Genauigkeit und Auflösung bieten• begrenzte Informationen (z. B. weder genaue Form noch Farbinformationen) bekommen• das Problem wegen der gegenseitigen Beeinflussung von Radarsensoren haben• schlechte Azimut- und Höhenauflösung verfügen• ohne einer Erhöhung der Leistung Radardämpfung zeigen

Ultraschall-sensor	<ul style="list-style-type: none"> • lange Strecken bei schlechten Sichtverhältnissen vor dem Auto sehen • klein, leicht und erschwinglich sind • weniger Strom als ein Lidar-Sensor benötigen • im Vergleich zu Lidar robuster gegen Ausfälle sind 	<ul style="list-style-type: none"> • eine geringe Genauigkeit und Auflösung bieten • begrenzte Informationen (z. B. weder genaue Form- noch Farbinformationen) bekommen • das Problem wegen der gegenseitigen Beeinflussung von Radarsensoren haben • schlechte Azimut- und Höhenauflösung verfügen • ohne einer Erhöhung der Leistung Radardämpfung zeigen
LiDAR-Sensor	<ul style="list-style-type: none"> • große Entfernungen vor dem Auto bei guten Sichtverhältnissen erfassen • volle 360°- und 3D-Punktwolken bieten • eine gute Genauigkeit und Auflösung haben • keine signifikanten Interferenzen bei mehreren Lidarsensoren haben 	<ul style="list-style-type: none"> • teurer als Radar und Kamera sind • kleine Objekte (wie Drähte und Stangen) nicht entdecken können • eine schlechte Kontrastunterscheidung bei der Erkennung nasser Oberflächen haben • durch unterschiedliche klimatische Bedingungen beeinflusst werden

Im Rahmen dieser Arbeit sind die am iff (Institut für Fahrzeugtechnik) bereits bestehende Fahrzeugarchitektur mit Ibeo LUX Laserscanner versehen. Daher wird folgend in Abschnitt 2.2.2 auf der Mechanismus und das darauf resultierende Sensormodell des Laserscanners eingegangen. Außerdem werden die technische Details bei Einführung der inversen Sensormodellierung vorgestellt, weil die reale technische Größen dabei ein wichtiger Faktor sind.

2.2.2 Laserscanner

Mechanismus

Laserscanner beruht auf dem Prinzip ToF (Time-of-flight). Nach diesem Prinzip wird die Entfernung zwischen dem Ziel und Laserscanner dadurch berechnet, dass die Zeit gemessen wird, die ein Lichtimpuls benötigt, um von der Lichtquelle zum beobachteten Ziel und dann zum Detektor (normalerweise zusammen mit der Lichtquelle) zu gelangen [SK08].

3 Implementierung

Um das ober

3.1 Unterkapitel 1

Beispiel für eine Fußnote².




Abbildung 3.8: Folgefahrt Beispielbild

Wie in 3.1 gezeigt, ist es möglich, Kapitel zu [?]verlinken. Abkürzungen wie das Institut für Fahrzeugtechnik (IfF) werden so dargestellt. Quellen übrigens so [?].

Abbildung 3.8 soll ein Beispielhaftes Bild zeigen.

3.1.1 Unterunterkapitel1

Möglichkeit zur weiteren Unterteilung – Teilkapitel Mehr als drei Unterteilungsebenen sollen vermieden werden!

²Fußnoten sind gut.

Eingerücktes Teilkapitel Derartige Dinge wie eingerückte Teilkapitel gibt es auch. Falls Du sie brauchen solltest.

Tabelle 3.1: Tabular Umgebung: Simpel formatierte Tabelle

Zwei miteinander verbundene Zellen	
Punkt 1	Adaptive Cruise Control
Punkt 2	Lane Keeping Assist
Schon wieder zwei miteinander verbundene Zellen	
Punkt 3	Elektronisches Stabilitätsprogramm

Nachfolgend das Beispiel für eine Aufzählung mit Itemize.

- Reaktionszeit Δt_{react}
- Im oberen Punkt sieht man auch schön die Einbindung von Formeln in den Text.

$v_{Obj.} = 120 \text{ km/h}$
Einheiten sollten nicht kursiv dargestellt werden und werden vom Zahlenwert durch ein schmales Leerzeichen (Backslash und Komma) getrennt.

Es gibt eine Vielzahl von Gleichungsumgebungen. Equation ist eine davon. Die Gleichung ergibt natürlich keinen tieferen Sinn:

$$x_{obj} = \frac{s^2 \cdot a \cdot \sqrt{b}}{234 \cdot h_{ego}}$$

(3.1)

Tabelle 3.2: Vorteile und Nachteile von Kamera, Radar-, Lidar- und Ultraschallsensor

Sensor	Vorteile	Nachteile
Kamera	<ul style="list-style-type: none"> • eine hohe Auflösung und Farbskalen über das gesamte Sichtfeld haben • eine farbenfrohe Perspektive der Umgebung bieten • eine 3D-Geometrie von Objekten bei Stereokameras bereitstellen • kostengünstig Im Vergleich zu Lidar sein 	<ul style="list-style-type: none"> • ein leistungsfähiges Berechnungssystem benötigen, um nützliche Daten zu extrahieren • empfindlich auf starken Regen, Nebel und Schneefall reagieren • eine 3D-Geometrie von Objekten bei Stereokameras bereitstellen • begrenzte Reichweite besitzen
Radarsensor	<ul style="list-style-type: none"> • lange Strecken bei schlechten Sichtverhältnissen vor dem Auto sehen • klein, leicht und erschwinglich sind • weniger Strom als ein Lidar-Sensor benötigen • im Vergleich zu Lidar robuster gegen Ausfälle sein 	<ul style="list-style-type: none"> • eine geringe Genauigkeit und Auflösung bieten • begrenzte Informationen (z. B. weder genaue Form noch Farbinformationen) bekommen • das Problem wegen der gegenseitigen Beeinflussung von Radarsensoren haben • schlechte Azimut- und Höhenauflösung verfügen • ohne einer Erhöhung der Leistung Radardämpfung zeigen
Ultraschallsensor	<ul style="list-style-type: none"> • lange Strecken bei schlechten Sichtverhältnissen vor dem Auto sehen • klein, leicht und erschwinglich sind • weniger Strom als ein Lidar-Sensor benötigen • im Vergleich zu Lidar robuster gegen Ausfälle sein 	<ul style="list-style-type: none"> • eine geringe Genauigkeit und Auflösung bieten • begrenzte Informationen (z. B. weder genaue Form noch Farbinformationen) bekommen • das Problem wegen der gegenseitigen Beeinflussung von Radarsensoren haben • schlechte Azimut- und Höhenauflösung verfügen • ohne einer Erhöhung der Leistung Radardämpfung zeigen

Tabelle 3.3: Tabular Umgebung: Etwas komplexere Tabelle

	Fahrzeug-CAN	GPS-System	ESP-Cluster	Correvit	Lichtschranke	Radar	Lidar	Kreiselform	Webcam, Leuchtdiode
Subjekt									
Setzgeschwindigkeit									x
relative Größen									
Triggersignal		x			x				x
Objekt									
Längsgeschwindigkeit	x	x		x					

Literatur

- [.0619] *2019 IEEE International Conference on Robotics and Biomimetics (RO-BIO)*. IEEE, 06/12/2019 - 08/12/2019 . – ISBN 978–1–7281–6321–5
- [BGC⁺19] BADUE, Claudine ; GUIDOLINI, Rânik ; CARNEIRO, Raphael V. ; AZEVEDO, Pedro ; CARDOSO, Vinicius B. ; FORECHI, Avelino ; JESUS, Luan ; BERRIEL, Rodrigo ; PAIXÃO, Thiago ; MUTZ, Filipe ; VERONESE, Lucas ; OLIVEIRA-SANTOS, Thiago ; SOUZA, Alberto Ferreira D.: Self-Driving Cars: A Survey. (2019)
- [Bus05] BUSCHKA, Pär: *Örebro studies in technology*. Bd. 20: *An investigation of hybrid maps for mobile robots*. Örebro : Universitetsbiblioteket, 2005. – ISBN 91–7668–454–7
- [Elf89] ELFES, Alberto: Using occupancy grids for mobile robot perception and navigation - Computer. In: *IEEE* 22, No. 6 (1989), S. 46–57
- [FHR⁺20] FAWAD AHMAD ; HANG QIU ; RAY EELLS ; FAN BAI ; RAMESH GOVINDAN: CarMap: Fast 3D Feature Map Updates for Automobiles. In: *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. Santa Clara, CA : USENIX Association, 2020. – ISBN 978–1–939133–13–7, 1063–1081
- [Heg18] HEGERHORST, Torben: *Entwicklung eines Umfeldmodells für das automatisierte Fahren*. Braunschweig, Technische Universität Braunschweig, Masterarbeit, 2018
- [MAA⁺20] MOHAMMED, Abdul S. ; AMAMOU, Ali ; AYEVIDE, Follivi K. ; KELOUWANI, Souso ; AGBOSSOU, Kodjo ; ZIOUI, Nadjat: The Perception System of Intelligent Ground Vehicles in All Weather Conditions: A Systematic Literature Review. In: *Sensors (Basel, Switzerland)* 20 (2020), Nr. 22. <http://dx.doi.org/10.3390/s20226532>. – DOI 10.3390/s20226532
- [Pie13] PIERINGER, Christian: *Modellierung des Fahrzeugumfelds mit Occupancy Grids*. Passau, Universität Passau, Masterarbeit, 2013

-
- [SK08] SICILIANO, Bruno ; KHATIB, Oussama: *Springer handbook of robotics*. Berlin and London : Springer, 2008. – ISBN 978–3–540–23957–4
- [TBF05] THRUN, Sebastian ; BURGARD, Wolfram ; FOX, Dieter: *Probabilistic robotics*. Cambridge, Mass. and London : MIT, 2005 (Intelligent robotics and autonomous agents). – ISBN 978–0–262–20162–9
- [WHLS15] WINNER, Hermann ; HAKULI, Stephan ; LOTZ, Felix ; SINGER, Christina: *Handbuch Fahrerassistenzsysteme: Grundlagen, Komponenten und Systeme für aktive Sicherheit und Komfort / Hermann Winner, Stephan Hakuli, Felix Lotz, Christina Singer (Hrsg.)*. 3., überarbeitete und ergänzte Auflage. Wiesbaden : Springer Vieweg, 2015 (ATZ/MTZ-Fachbuch). – ISBN 978–3–658–05734–3
- [WSD07] WEISS, Thorsten ; SCHIELE, Bruno ; DIETMAYER, Klaus: Robust Driving Path Detection in Urban and Highway Scenarios Using a Laser Scanner and Online Occupancy Grids. In: *2007 IEEE Intelligent Vehicles Symposium*, IEEE, 13/06/2007 - 15/06/2007. – ISBN 1–4244–1067–3, S. 184–189
- [WSG10] WURM, Kai M. ; STACHNISS, Cyrill ; GRISETTI, Giorgio: Bridging the gap between feature- and grid-based SLAM. In: *Robotics and Autonomous Systems* 58 (2010), Nr. 2, S. 140–148. <http://dx.doi.org/10.1016/j.robot.2009.09.009>. – DOI 10.1016/j.robot.2009.09.009. – ISSN 09218890

Anhang

Hier sind zusätzliche Infos einzubringen

Das Beispiel für eine Tabbing Umgebung zeigt, dass es möglich ist, mehrere Zeilen mit dem gleichen Einzug darzustellen:

$$v_{Start} = 120 \text{ km/h} = 33,3 \text{ m/s}$$

$$v_{End} = 80 \text{ km/h} = 22,2 \text{ m/s}$$

$$v_{Diff} = 40 \text{ km/h} = 11,1 \text{ m/s}$$